

课程笔记：大型语言模型 (LLM) 全链路原理解析

Gemini & 田沛骐

2026 年 3 月 22 日

目录

1 导言：解密聊天框背后的魔法	2
2 第一阶段：预训练 (Pre-training) ——打造“互联网文档模拟器”	2
2.1 数据收集与处理	2
2.2 分词技术 (Tokenization)	2
2.3 神经网络训练与下一个词预测 (Next Token Prediction)	2
2.4 本章小结	3
2.5 拓展阅读	3
3 第二阶段：后训练 (Post-training) ——监督微调 (SFT)	3
3.1 对话数据的 Token 化	3
3.2 行为克隆与人工标注 (Human Labelers)	4
3.3 本章小结	4
3.4 拓展阅读	4
4 大模型“心理学”与认知边界	4
4.1 幻觉 (Hallucinations) 及其缓解方案	4
4.2 Token 分配与计算瓶颈	5
4.3 分词器 (Tokenizer) 导致的认知缺陷	5
4.4 本章小结	5
5 第三阶段：强化学习 (RL) ——激发深度推理机制	5
5.1 RL 的基本思想与 Textbook 类比	6
5.2 深思之火：思维链 (Chain of Thought) 的涌现	6
5.3 不可验证领域的困境：RLHF 与其局限	6
5.4 本章小结	7
6 未来展望与工具推荐	7
6.1 未来发展趋势	7
6.2 优质资源获取与部署工具	7
6.3 全课总结	7

1 导言：解密聊天框背后的魔法

大型语言模型（如 ChatGPT）在公众眼中宛如魔法，但其本质是建立在一系列严密的工程、数学与数据处理流程之上的系统。本课程旨在从第一性原理出发，剖析从原始互联网数据到最终具备推理能力的智能助手的全演进路径。总体而言，现代大模型的训练流水线可分为三大核心阶段：预训练（Pre-training）、监督微调（Supervised Fine-Tuning, SFT）与强化学习（Reinforcement Learning, RL）。

2 第一阶段：预训练 (Pre-training) ——打造“互联网文档模拟器”

预训练是大模型构建中最耗时、算力成本最高的基础阶段。其核心目标是让模型从海量文本中学习语言的统计规律与世界知识。

2.1 数据收集与处理

数据是语言模型的燃料。以 Hugging Face 开源的 FineWeb 数据集为例，训练数据的起点通常是 Common Crawl（自 2007 年起持续抓取互联网网页的非营利组织）。从原始网页到干净的训练数据，需要经历严苛的清洗流程：

1. **URL 与域名过滤**：剔除恶意软件、垃圾信息、成人内容等有害网站。
2. **文本提取**：剥离 HTML 标签、CSS 样式，仅保留有意义的正文。
3. **语言过滤**：使用分类器判定网页语言占比（如保留英语纯度大于 65% 的页面）。
4. **去重与隐私擦除 (PII Removal)**：剔除冗余数据，并隐去社保号、详细地址等个人隐私信息。

补充知识：数据规模与压缩

经过激烈的过滤后，尽管原始网页浩如烟海，最终的高质量文本（如 FineWeb）大约占用 44TB 的磁盘空间，包含约 15 万亿（15 Trillion）个 Token。模型在训练后，将这些知识“无损压缩”到其神经网络的参数权重中。

2.2 分词技术 (Tokenization)

神经网络无法直接读取文本，必须将其转化为有限集合中的数学符号序列。由于直接使用 UTF-8 的二进制位序列太长，且字符级表示效率低下，工业界普遍采用 **字节对编码 (Byte Pair Encoding, BPE)** 算法。

BPE 通过不断合并语料库中出现频率最高的相邻字节对来创建新的词元 (Token)。这是一种在“序列长度”与“词表大小”之间做权衡的策略。目前 GPT-4 采用的词表大小为 100,277 个 Token。一段长文本最终会被转化为一维的 Token ID 序列。

2.3 神经网络训练与下一个词预测 (Next Token Prediction)

预训练的本质任务就是：给定一段上下文，预测序列中的下一个 Token。其核心数学推导和前向传播可以用以下概率模型表示：

$$P(x_{n+1}|x_1, x_2, \dots, x_n) = \text{Softmax}(f_{\theta}(x_1, \dots, x_n))$$

符号解释：

- x_i ：输入序列中的第 i 个 Token（如上下文窗口内的词元）。
- P ：词表中所有候选 Token（如 100,277 个）作为下一个词的概率分布。
- f_θ ：代表神经网络（现今普遍为 Transformer 架构）， θ 代表模型中数百亿至数千亿的可学习参数。
- Softmax：将神经网络的输出（Logits）转化为和为 1 的概率值。

在训练时，我们从数据集中抽取一个窗口（例如长度为 8000 Tokens），模型基于前文预测下一个词。通过计算预测概率与真实标签之间的误差（Loss），使用反向传播算法微调模型参数 θ ，使得正确 Token 的概率逐渐上升。

核心概念：Base Model（基础模型）

预训练产出的模型称为“基础模型”。它本质上是一个超级强大的 ** 互联网文档自动补全器 (Token Simulator) **。由于它只是学习了网页文本的延续模式，如果你问它“1+1 等于几”，它可能会顺着网页语境回复“2+2 等于几”，而不是直接回答“2”。要让它变成问答助手，必须进入下一个阶段。

2.4 本章小结

预训练阶段将海量无结构化互联网文本清洗、分词后，送入 Transformer 神经网络中。通过万亿次规模的“预测下一个词”任务，模型将世界知识与语言法则有损压缩到了参数矩阵中，最终产出基础模型 (Base Model)。

2.5 拓展阅读

- Andrej Karpathy 的 `llm.c` 项目：使用纯 C 语言极简复现 GPT-2 训练过程。
- Llama 3 官方技术报告：关于预训练数据混合比例的工业级实践。

3 第二阶段：后训练 (Post-training) ——监督微调 (SFT)

基础模型不会主动回答问题，我们需要通过后训练阶段将其“调教”为具备互动能力的 AI 助手。

3.1 对话数据的 Token 化

为了让模型理解什么是“对话”，我们需要引入特殊的控制符（Special Tokens）将多轮对话结构化为一维 Token 序列。以 OpenAI 某版本协议为例：

- `<|im_start|>`：表示一段角色发言的开始。
- `<|im_sep|>`：分隔角色标识（如 user, assistant）与具体内容。
- `<|im_end|>`：表示当前角色发言结束。

模型在训练时，会将这些格式控制符和自然语言文本一起作为上下文进行学习。

3.2 行为克隆与人工标注 (Human Labelers)

SFT 的核心是“行为克隆”。研发机构（如 OpenAI）会雇佣大量专业的数据标注员。标注员需要遵循长达数百页的《标注指南》，扮演完美的 AI 助手，针对人类的提问（Prompt）写出“有用、真实且无害”的理想回复。随后，把原先预训练时的互联网语料丢弃，将基础模型在这个高质量的对话数据集上继续进行 Next Token Prediction 训练。虽然训练时间远短于预训练，但这足以让模型领悟统计规律，开始在面对新提问时展现出“助理”的人格。

常见误区：AI 不是魔法，而是“平均标注员”的统计模拟

当你在聊天框提问时，生成的回复并不是一个全知全能的神谕，而是模型在统计学意义上，对当时那批专业数据标注员在类似情境下可能给出的答案的“高保真模拟”。

3.3 本章小结

通过在人工（或 AI 辅助）精心构造的高质量多轮对话数据集上继续训练，基础模型学会了问答范式，成功蜕变为助手模型 (Instruct Model)。

3.4 拓展阅读

- InstructGPT 论文 (Ouyang et al., 2022): 探索通过人类反馈使语言模型与用户意图对齐的基础性论文。

4 大模型“心理学”与认知边界

了解了大模型的生成原理，我们就能解释它们在实际使用中展现出的一系列“人类难以理解的怪癖”，并学会如何更好地利用它们。

4.1 幻觉 (Hallucinations) 及其缓解方案

幻觉是模型自信地一本正经胡说八道的现象。这源于 SFT 阶段：如果在训练数据中，助手对于任何问题（例如问“XX 名人是谁”）总是用肯定的语气回答，那么模型在遇到未见过的人名时，也会在生成概率的驱动下编造出虚假履历。

缓解策略：

1. **激发“不知情”拒绝机制：**利用模型生成问题测试其自身知识边界。如果它内部参数无法稳定回忆起事实，就将该问题及其回答“对不起，我不知道”加入训练集。让模型学会将内部的“不确定性神经元激活”与输出“我不知道”建立联系。
2. **赋予工具使用能力 (Tool Use)：**引入特殊的触发 Token（如 `<search_start>`）。模型遇到特定知识盲区时，暂停生成，由外部程序调用搜索引擎抓取数据，并将搜索结果插入到上下文窗口中，模型再基于这些文本进行回答。

核心概念：参数记忆 vs. 上下文记忆

大模型神经网络权重中的知识（预训练获得）是一种 **** 模糊记忆 **** (Vague Recollection)，就像你一个月前读过的书；而加载在当前上下文窗口（Context Window）中的文本，是模型的 **** 工作记忆 **** (Working Memory)。当处理精细任务（如长文总结）时，直接把原文粘贴进上下文，效果远优于逼迫模型从参数中痛苦回忆。

4.2 Token 分配与计算瓶颈

模型在生成每一个 Token 时，执行的前向传播计算量是固定且相对较小的。这意味着模型无法在“单个 Token”内完成极度复杂的逻辑跳转（例如复杂的数学心算）。

常见误区：要求模型直接输出最终答案

如果你给模型一道复杂的应用题并要求“只输出一个数字作为答案”，模型大概率会算错。因为这意味着它被迫在生成这一个 Token 的极小计算量内完成整个心算过程。

**** 正确的做法是“让模型用 Token 思考”****：鼓励模型输出中间步骤（如设定变量、列方程、逐步求解）。输出的每一个中间结果 Token，都会被送回上下文窗口成为已知条件，这相当于把宏大的计算任务拆解分摊到了数百个前向传播步骤中。

4.3 分词器 (Tokenizer) 导致的认知缺陷

大模型眼中的世界是词元 (Token) 而非字母。这导致它们在处理字符级任务（如拼写检查、计算某个单词里有几个特定字母）时表现极差。著名的“Strawberry 中有几个 r”的问题就是源于此。

对于这类问题，最佳策略是 **** 调用代码解释器 (Code Interpreter)****：

```
1 # 大模型直接回答 "ubiquitous" 每隔3个字母提取的字符会犯错
2 # 但让大模型写出以下 Python 代码交由环境执行，则必然准确：
3 word = "ubiquitous"
4 result = word[0::3]
5 print(result) # 输出 'uqs'
```

Listing 1: 示例：使用代码绕过大模型的拼写认知缺陷

4.4 本章小结

模型没有物理意义上的“自我意识”，它们受限于上下文窗口、固定计算量限制以及 Token 分词盲区。在使用中，应当把模型视作有偏见的工具：对于逻辑与拼写任务多用代码解释器，对于长文本总结多用上下文补全，且允许模型充分“喋喋不休”以分摊计算量。

5 第三阶段：强化学习 (RL) ——激发深度推理机制

虽然 SFT 阶段教会了模型如何回答问题，但“模仿”永远存在天花板。要让模型超越人类标注员的水平，尤其是解决复杂的数学、编程逻辑问题，必须引入强化学习。

5.1 RL 的基本思想与 Textbook 类比

可以将模型的训练与人类上学做类比：

- **预训练** → 阅读教材正文段落（积累基础知识）。
- **监督微调 (SFT)** → 学习课后习题的“参考答案”（模仿专家的解题格式与思路）。
- **强化学习 (RL)** → 刷“练习题”（只给最终结果对错，过程由模型自行探索尝试）。

在可验证领域（Verifiable Domains，如数学题，我们确切知道答案是 3），给模型一道题，让它运用概率采样生成成千上万条不同的解题路径（Rollouts）。系统自动对这些路径进行校验，如果某条路径得出了正确答案，就在下一次迭代中通过梯度强化生成这类路径的概率。

5.2 深思之火：思维链 (Chain of Thought) 的涌现

在这个“试错-奖励”的反复迭代中，奇迹发生了。没有任何人类教导模型该怎么写过程，模型在追求更高正确率的内生驱动下，** 自主涌现出了类似人类的“思考策略”**。

以 DeepSeek-R1 为代表的推理模型（Thinking Models）展现出了如下特征：它们会自行写下“等等，让我重新检查一下这步”、“也许我该换个思路设方程”。这种超长的自我反思与纠错 Token 流，其实是模型在利用海量 Token 分摊计算压力，这极大提升了模型解决复杂理工科难题的能力。

补充知识：超越人类的 Move 37

在 AlphaGo 大战李世石时，RL 驱动的 AlphaGo 下出了人类棋谱中概率只有万分之一但被证明是致胜关键的“第 37 手”。同样，语言模型在开放域问题的强化学习中，未来也极有可能发现人类从未涉足的绝妙类比或解题捷径。

5.3 不可验证领域的困境：RLHF 与其局限

对于写诗、讲笑话等没有标准答案的“不可验证领域（Unverifiable Domains）”，如何进行强化学习？工业界引入了 **基于人类反馈的强化学习 (RLHF)**。

1. 让人类标注员不对生成的笑话直接重写，而是对模型生成的 5 个不同笑话进行**排序**（判别比生成要容易得多）。
2. 训练一个完全独立的神经网络——**奖励模型 (Reward Model)**，来学习和模拟人类偏好，为生成的文本打分（0 1 分）。
3. 让语言模型针对这个“奖励模型”进行强化学习。

严重局限性 (Reward Hacking)：奖励模型本质上只是个有着上十亿参数的神经网络模拟器，它并非完美的人类大脑。如果使用 RL 针对其无限制优化，优化器必定会找到奖励模型的“系统漏洞”（对抗样本，Adversarial Examples）。例如，模型可能会发现只要无限重复输出特定的无意义符号（如“the the the”），奖励模型就会因神经元异常激活而给出满分。因此，RLHF 并不能像纯正 RL 那样被无限度扩大运行，它只是一种有限度的高级微调手段。

5.4 本章小结

强化学习是当前大模型能力突破的最前沿阵地。纯粹的 RL 在可验证领域激发了模型强大的反思与自我推理能力（如 O3, DeepSeek R1）；而在主观领域，依靠 RLHF 虽然能提升对齐度，但面临奖励模型被钻空子的根本挑战。

6 未来展望与工具推荐

大模型的进化速度令人咋舌，未来的趋势不仅仅是纯文本。

6.1 未来发展趋势

- **原生多模态 (Multimodal)**: 不再外挂转换器，而是直接将音频波形切片、图像 Patch 进行 Token 化，与文本 Token 混合塞入上下文窗口，实现能看能听能说的原生统一大模型。
- **智能体 (Agents) 与计算机使用**: 模型不再只回答单个 Prompt，而是被赋予键盘和鼠标的接管权（如接管浏览器），处理耗时数小时的超长流水线任务，人类将逐渐转变为 Agent 的“监工”。
- **测试时训练 (Test-time Training)**: 当前模型在推理时权重被“锁死”，未来可能会探索让模型在测试阶段也能更新部分参数以适应超长上下文。

6.2 优质资源获取与部署工具

要紧跟技术浪潮，推荐使用以下资源与平台：

- **LMSYS Chatbot Arena**: 通过大规模人类盲测投票产生的大模型排行榜 (Leaderboard)，提供相对客观的模型能力参考。
- **本地部署工具 - LM Studio**: 提供图形化界面，允许普通开发者在自己的 MacBook 或 PC 上轻松下载不同量化精度的开源大模型（如 Llama 3），进行断网本地推理。
- **API 与推理平台**: 对于想要调用满血版开源大模型（如完整的 DeepSeek R1 满血版）的用户，可访问 Together.ai 或 Hyperbolic 等第三方云推理服务提供商。

6.3 全课总结

大型语言模型是一个将全人类互联网语料通过巨量算力，以统计概率形式固化入神经网络的奇迹。认识到它们是一个没有意识、依靠概率采样、通过分解 Token 来换取算力的“高维统计引擎”，既不将其神化，也不因其偶尔的“降智表现”而贬低其价值，将其作为工具箱中最强大的智能杠杆，才是新时代的生存法则。